

# 通过稀疏关联结构对齐方法实现的时间序列域自适应

蔡瑞初<sup>1</sup>、陈佳伟<sup>1</sup>、李子健<sup>1</sup>、陈伟<sup>1</sup>、张克力<sup>2</sup>、叶荣健<sup>2</sup>、卓张李<sup>1</sup>、杨晓燕<sup>1</sup>、张振杰<sup>1</sup>

<sup>1</sup>根据我们的知识,你应该知道什么

<sup>2</sup>

cairuichu@gdut.edu.cn, 陈家卫952@gmail.com, 请关注一下@gmail.com,  
张克利1@华为。叶永坚, 华为。请, @gmail。这个网站, 扬小燕@gmail.com,  
zhenjie.zhang@pvoice.io

## 摘要

在时间序列数据上的领域自适应是一项重要但具有挑战性的任务。在这一领域中, 现有的大多数工作都是基于在限制技术的帮助下学习数据的领域不变表示。然而, 由于时间戳之间的复杂性依赖性, 这种域不变表示的提取对于时间序列数据来说是一项简单的任务。在完全悬垂的时间序列中, 时间滞后或偏移量的微小变化可能会导致域不变性中的困难。幸运的是, 因果关系的稳定性激发了我们探索数据的变异结构。为了减少病因结构发现中的困难, 我们将其放宽到稀疏关联结构, 并提出了一种新的稀疏关联结构对齐模型。首先, 我们生成分割集来排除偏移集的障碍。其次, 设计了变量内和变量间稀疏注意机制, 提取考虑时间标签的关联支撑时间序列数据。最后, 利用结合结构对齐来指导知识从源域到目标蛋白的转移。Experimental 的研究不仅验证了我们的方法在三现实世界数据集上的良好性能, 而且还对转移的知识提供了一些深刻的发现

## 介绍

领域适应 (Pan和Yang2009; Long等2015; Cai等2019) 利用标记的源域数据和未标记的目标域数据, 具有广泛的应用范围 (Ganin和Lipson2015; Lin和Lu2018)。为了解决众所周知的domain转移现象, 通过探索源域和目标域之间的各种假设, 提出了大量方法 (Tzeng等2014; Cai等2019; Zhang等2019)。

最广泛使用的假设是在源域和目标域中都存在域不变代表。由于这种假设在非时间序列数据中取得了良好的表现 (Cai等, 2019; 王等, 2019), 研究人员通过使用循环神经网络 (RNN) (2010) 和变分版权©2021 (www.aaai.org), 将其扩展到时间序列数据。保留所有权利。




图1: “血糖(B)↓”、“胰高血糖素(G)↑”和“胰岛素(I)↑”中人体生理机制的说明。“血糖”的降低导致“胰高血糖素”的减少, 而“胰岛素内”的增加。彩色的blocks表示变量的变化片段。不同的红双头行的长度表示不同的偏移量。蓝色双头箭头的不同长度表示“血糖”和“胰高血糖素”之间的反应时间不同。不同的反应时间意味着不同的时间滞后。(彩色上的最佳视图。)

RNN (Chung等人, 2015年), 从时间序列中学习表示, 并使用梯度反转层 (GRL) 来对齐从源数据和目标时间序列数据中学习到的表示。

然而, 从时间序列数据中提取域不变信息是一项具有挑战性的任务。现有的药物 (da Costa等人2020; 等人2017), 简单地使用基于RNN的特征提取器, 本质上假设连续分布是相等的 (Pan等人。 (y jφ (x1、x2、⋯、x t) ) = P T (y jφ (x1、x2、⋯、x t) ), 在whichφ (⋅) 中是特征反式映射。这个假设适合于静态数据, 但在时间序列数据中难以满足。以图1为例, 由于时间戳之间复杂的依赖结构, 即使来自不同域的微小差异 (例如偏差和时间滞后的变化) 也可能导致难以学习域不变的代表。此外, 对于多变量时间序列数据, 变量并不总是i.i.d.的现有的时间序列域自适应方法忽略了变量之间的关联结构, 可能会出现过拟合问题。

基于图2(a)的玩具示例, 来自源域和目标域的数据共享相同的稳定性




图2：六种不同结构的说明

时间数列(a)变量的因果结构。(b)现有的方法考虑了实际的独立关系，并导致过度使用。(c)受因果机制稳定性的启发，我们的方法考虑了变量之间的稳定和稀疏关联结构。

因果结构（如“血糖↓”(B)、“胰高血糖素↓”(G)和“胰岛素↑”(I)的生理机制如图1所示），是域不变的。然而，如图2(b)所示，现有的方法只考虑地面真实关联结构，还考虑冗余关系，这导致了超拟合。由于来自不同域的原因结构是相同的，因此来自源和目标域的时间序列数据也具有相似的关联结构。图2(c)给出了另一个有见地的例子，表明考虑域-非变量关联结构和排除域-特定关联是重要的，可以使模型健壮和泛化。

然而，如何解释时间序列数据中变量之间的关联结构是另一个挑战，这是由时间间隔和偏移量等众所周知的差异引起的。根据人体的生理力学，“B血糖”的减少导致“胰高血糖素”的减少和“胰岛素”的增加，生理机制的响应时间随年龄和种族而变化，导致时间滞后（即图1中来自源和目标域的蓝箭头长度不同）。假设老年患者的源域数据和年轻患者的目标域数据，老年患者的响应时间比年轻患者长。同时，相同的m机制经常发生在不同的起点上，如来自不同区域的不同偏移量（即图1中红双箭头的不同长度）。现有的工作是简单地采用rnn作为特征提取器来提取域不变表示，不能排除时间滞后和偏移的影响，也不能提取关联结构。

基于上述直觉，我们提出了时间序列的稀疏关联结构对齐（SASA）方法

domainadaptation.SASA的主要挑战可以归纳为两方面。

(1)如何摆脱时间滞后和偏移的理论结构来提取沥青质结构？(2)如何提取公共关联结构，并进一步提取域不变重构？为了解决这些问题，首先，我们提出了自适应分段摘要，以减轻偏差的障碍。其次，该模型提取了时间序列数据的变量间注意机制和变量间注意机制的稀疏关联结构。第三，我们的模型通过简单地调整结构结构，将稀疏关联结构从源域转移到目标域。大量的实验研究表明，我们的SASA模型在三个真实的世界数据集上优于最先进的时间序列无监督域的附加方法。

## 相关工程

在本节中，我们主要关注现有的无监督域自适应和时间域自适应技术。

在非时间序列数据上的域自适应。非监督领域自适应的主流方法（Pan et al. 2010；Wei、Ke和Goh, 2016,2018；Wen等人，2019）的目的是提取源域和目标域之间的域不变表示。最大平均离散性（MMD）是利用核再现希尔伯特空间最流行的方法之一（Tzeng et al. 2014）。Sun等人（Sun、Feng和Saenko2016）提出了无监督领域适应的二阶统计方法。和Long等人（Longetal.2015）通过我们采用最优的多核选择方法来减少域的差异。

无监督域映射的另一种基本方法是借用生成对抗网络的思想来提取域不变表示（Goodfelleetal.2014）。Ganin等人

引入梯度反转层来欺骗域分类器，并进一步提取域的识别方法。Tzeng等人（Tzengetal.2017）提出了一种新的对抗性领域适应的统一框架。最近，考虑到细粒度对齐和瞄准来消除错误对齐。Xie等人（Xi eetal.2018）通过将源域和目标域的关联值对齐，解决了无监督域自适应问题。

在这些事件的因果关系观点下，不适应情景可以由因果机制决定。Zhang等人讨论了目标移、条件移和广义条件移（Zhangetal.2013）。在前者的基础上，热曼等（日尔曼等2016）和张等（张、龚和施尔科普夫2015）对域适应背景下的广义目标转移进行了更多的研究。最近，Cai等人（Cai等人，2019年）遵循数据生成过程的因果模型，通过提取恢复的触角空间上的解纠缠语义表示来解决这个问题。

本文研究了对时间序列数据的无监督的主自适应问题。我们的SASA方法

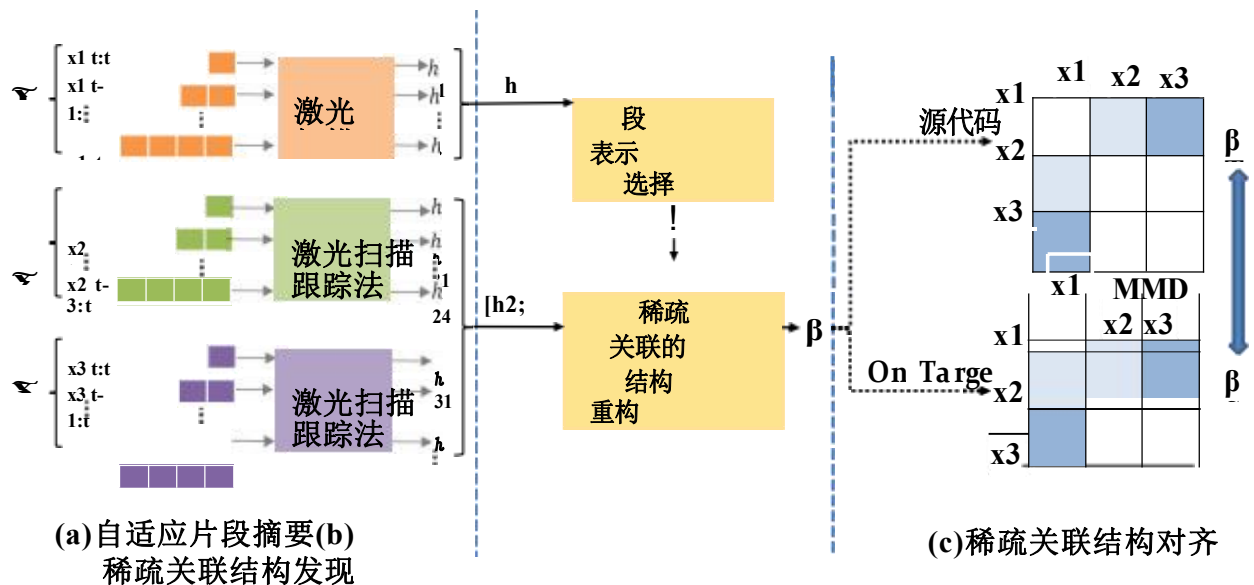


图3：稀疏关联结构对齐模型的框架。(a)具有可变特异性LSTM的适应性片段总结过程。(b)通过变量内和变量间的注意机制发现稀疏关联结构。(c)源和目标域之间的稀疏关联结构对齐。(最佳彩色视图。)

首先受到观察数据的病因机制的启发。我们进一步考虑一个更宽松的稀疏关联结构，因为任意两个变量包含的因果结构也具有关联结构。

**时间序列数据上的域自适应。**近年来，时间序列数据的非监督域适应受到了越来越多的关注。D是一个海岸等人。(da Costa等人。

采用最直接的方法，简单地用基于RNN的特征提取器代替特征提取器来提取时间序列数据的表示。普鲁索瑟姆等(普鲁索瑟姆等2017)使用RNN(Chung等2015)提取潜在代表时间序列。在时间序列领域适应方面的工作有限。一种可能的解决方案是对非时间序列数据的无监督域附加方法对时间序列数据的有向张力。然而，这种简单的方法可能不能在时间序列数据中工作，因为很难在所有时间戳中对齐观察到的数据的条件分布。

由于现有的时间序列域适应方法(da Costa et al. 2020; 不能很好地调整时间序列数据的条件分布，我们提出了一种新的时间序列数据域适应方法，以提取稀疏关联结构并过滤特定领域的信息。

## 稀疏关联结构排列

在这一节中，我们详细阐述了我们的稀疏作为社会对齐(SASA)模型，该模型研究了稀疏的结构，并从时间序列数据中提取了域不变信息。在这一节中，我们首先提出了这个问题。然后，我们提供了我们的模型的细节。

## 问题制定和概述

在这项工作中，我们重点关注了时间序列数据的非监督域自适应问题。我们让 $x = \{x_{t-N+1}; \dots; x_{t-1}; x_t\}$ 表示一个具有N个时间步长的多变量时间序列样本，其中 $x_t \in \mathbb{R}^M$ ， $y \in \mathbb{R}$ 是对应的标签。我们假设 $PS(x; y)$ 和 $PT(x; y)$ 是源和目标域的不同分布，但是由共同的因果机制产生的。由于同一因果结构产生的两个变量集应该具有相同的关联结构，因此 $PS(x; y)$ 和 $PT(x; y)$ 具有相同的关联结构。 $(X_S; Y_S)$ 和 $(X_T; Y_T)$ 分别从 $PS(x; Y)$ 和 $PT(X; Y)$ 采样，表示源和目标主数据集。然后我们进一步假设每个源-主样本 $x$ 都带有 $y_S$ ，而目标域没有标记样本。我们的目标是设计一个预测模型，可以从目标域预测给定的时间序列样本 $x_T$ 的 $y_T$ 。

为了实现这一目标，我们的目标是扩展 $t$ 以关联结构形式的域不变表示。这个解决方案的灵感来自于直觉，即原因关系在各个领域中是不变的。由于学习因果结构的复杂性，我们放宽了因果结构的解释。考虑到偏移量随域的不同而变化，阻碍了模型提取域不变的关联时间结构，我们首先阐述了如何获得时间序列数据的细粒度沉积物，以缓解偏移量的障碍。因此，我们通过变量内适应离子机制和变量间注意机制来重建关联结构，并考虑了不同效应域的时间滞后。与现有的对齐来自不同领域的特征的工作不同，我们的SASA模型将共同的关联结构从不同的领域对齐到

间接提取域不变表示。

## 自适应段Summa化

在本小节中，我们将详细说明如何获得候选片段来消除偏移量的障碍。如图1所示，橙色块的持续时间变化具有不同的域，表示变量“B”的变化段。现有的方法采用整个时间序列数据输入，当变量开始和一个变量影响其他变量时，即任何变量的影响范围，不能准确捕获。因此，这些测量方法不能解决偏移量的噪声（即，在时间序列的起始点和片段的起始点之间的持续时间）。

为了解决上述问题，我们首先提出了自适应分段摘要。得到第*i*个时间序列*x<sub>i</sub>*的候选段

{*x<sub>i</sub>**t*-*N*+1, ..., *x<sub>i</sub>**t*-1, *x<sub>i</sub>**t*}，我们构造了多个线段每个变量*x<sub>i</sub>*的长度都不同。我们有：

$$x_i t - \tau + 1 : t$$

受RIM（Goyal等人，2019年）的激励，我们为每个变量分配了一个独立的LSTM。详细地，给定有*τ*个时间步长的第*i*个变量，我们有：

$$h_i t = f(x_i t - \tau + 1 : t; \theta_i), (2)$$

其中，*θ<sub>i</sub>*表示第*i*个LSTM的参数。注意，任何单变量时间序列*x<sub>i</sub>*的片段共享相同的LSTM，最后我们可以得到如下所示的分段表示集：

$$h_i = \{h_{i1}, h_{i2}, \dots, h_{iN}\}. (3)$$

由于最不可能从多变量时间序列数据中手动提取所有的前行为片段，所以我们首先通过上述处理获得所有候选片段的表示。选择最适合的片段代表，并用于重建关联结构。

## 稀疏关联结构的发现

在本节中，我们将介绍如何推广*m*个骨运动段的表征，以及如何借助非变量注意机制和变量间注意机制重建社会结构。

片段表示选择的变量注意机制。为了摆脱偏移带来的问题，我们需要借助自身注意机制更加关注所有候选段代表中的精确段表示（Vaswani et al. 2017）。按形式计算，*x<sub>i</sub>*各段的权重如下：

$$\frac{1}{\sqrt{d_h}} \sum_{k=1}^N (h_i W_Q)(h_k W_K)$$

$$\alpha_i = \{Q_i1, Q_i2, \dots, Q_i\tau, \dots, Q_iN\}$$

$$= \text{火花线} (u_{i1}, u_{i2}, \dots, u_{i\tau}, \dots, u_{iN}),$$

其中*W<sub>Q</sub>*, *W<sub>K</sub>*为可训练投影参数，*rs*, *√d<sub>h</sub>*为缩放因子。这是为了获得的

稀疏权值代表了特定的片段，我们选择了稀疏值

来计算权重。参数是参数 (*z*) = 最小 *p* ∈ Δ*K*-1 ||*z*||-*z*||<sub>2</sub>，它返回向量*z* ∈ *R<sup>K</sup>*的投影到概率单纯形 Δ*K*-1 的欧几里得投影。因此，我们得到了变量*x<sub>i</sub>*的加权分段表示如下：

$$Z_i = \tau Q_i \tau \cdot (h_i \tau W_V), (5) \sum_{i=1}^N$$

其中*W<sub>V</sub>*是可训练的投影参数。注that *α*也表示节段长度的概率。遗忘化，我们还考虑了给定变量段的硬脑膜随不同域而变化的情况。在这种情况下，为了更精确地重建关联结构，我们最小化源*α*和target域之间的最大平均差（MMD），以消除绝对的偏移量。它限制了线段从不同区域到边缘的持续时间，这有助于外部反应结构的转移。正式来说，我们有：

$$\sum_{m=1}^M \frac{1}{|\mathcal{X}_S|} \frac{1}{|\mathcal{X}_T|} \quad m=1, \dots, M \quad x \in \mathcal{X}_S, x \in \mathcal{X}_T \quad L\alpha = \|\Sigma \alpha_m - \Sigma \alpha\|$$

在which *α<sub>m</sub>* *S*中，and *α<sub>m</sub>* *T*表示的段的权值由式(4)计算出的源域和目标域的第*m*个变量。

稀疏关联结构重建方法的变量间注意机制。在变量内注意机制的帮助下，我们提取了加权节段代表的不满，尽管存在偏移量的障碍。然后利用这些加权分段表示来重建不同变量间的稀疏关联结构。索伊提出了变量间的关联机制来消除变量间的关联结构。

在这一部分中，我们的目标是重建变量之间的关联结构。我们不再使用变量内注意机制中的自我注意机制，而是采用“引用”注意机制（Bahdanau、Cho和Bengio2015）。计算变量与变量*j*关联程度的最直接的方法之一如下：

$$e_{ij} = (7) \frac{Z_i \cdot Z_j}{\|Z_i\| \cdot \|Z_j\|}$$

而由式计算得到的联想结构(7)忽略了*i*和*j*之间不同域的时间滞后。由于方程(7)不是指变量之间的时间间隔，因此关联结构可能是单独估计的。考虑到时间滞后，我们通过以下方法计算了变量*j*和变量*j*之间的关联程度：

$$\frac{Z_i \cdot h_{i\tau}}{\|Z_i\| \|h_{i\tau}\|}, (8) e_{ij\tau} = e_{ij} = \{e_{i1j}, e_{i2j}, \dots, e_{i\tau j}, \dots, e_{iNj}\}.$$

然后我们将这些关联度与稀疏-马克斯（马丁斯和Astudillo2016）作为内变量atten-

tion.正式来说，我们有：

$$\beta_i = \{\beta_{i1}, \beta_{i2}, \dots, \beta_{ij}, \dots, \beta_{iM}\} \quad (9)$$

$$= \text{参数} (\{e_{i1}, e_{i2}, \dots, e_{ij}, \dots, e_{iM}\}) (j, i) \neq$$

注，that $\beta_{ij} \in \beta_i$ 表示两者之间的联想强度  
变量i和变量j与s段持续时间of $\tau$ 有关。

## 稀疏关联结构排列

在本小节中，我们的目标是帮助时间序列数据的源域和目标域提取的关联结构，提取时间序列数据的域不变信息。

考虑到时间滞后，我们通过方程(8)和(9)重建了关联结构。为了解释域不变的关联结构，我们需要限制该结构与源域和目标域之间的距离。Since $\beta_{ij}$ 可以看作是i和j之间的关联强度分布，我们将结构距离测度的问题转化为分布度测度。在本文中，我们借用了域混淆网络(Tzeng et al. 2014)和利用最大平均差异(MMD)的思想来进行关联结构排列。正式来说，我们有：

$$L\beta = \|x S \beta m S - x T \beta m T\| \cdot (10) \sum_{m=1}^M \frac{1}{|\mathcal{X}_S|} \sum_{\epsilon \in \mathcal{X}} \frac{1}{|\mathcal{X}_T|} \sum_{\epsilon \in \mathcal{X}}$$

请注意，我们最小化了关联结构的附加矩阵，而不是像什么那样对齐特征(Tzeng等人。2014年)。

## 模型汇总

基于任务的标签预测器。我们的目标是得到与稀疏关联e structure $\beta$ 相结合的域不变表示。我们首先详细介绍了变量j的关联结构表示形式，如下所示：

$$U_{ij} = \beta_{ij} \tau \cdot h_{j\tau}, \sum_{\tau=1}^N \quad (11)$$

你我  $\sum_{\tau=1}^M$

因此，我们可以通过连接加权段表示和关联结构表示得到有效表示如下：

$$H_i = [Z_i; U_i]. \quad (12) \text{ 为方便起见}$$

，我们描述了上述过程：

$$H = GH(f(x; \Theta); W_Q, W_K, W_V), \quad (13)$$

其中GH实际上表示包含上述两种注意机制的特征提取器。 $H = [H_1; H_2; \dots; H_M]$ 表示该参数，我们进一步表示可变物种LSTM的 $p$ 参数。

在得到最终的表示法后，我们将H作为标签分类器 $rGy(\cdot; \phi)$ 的输入，其损失函数为 $L_y$ 。

对于分类问题，我们采用交叉熵作为标签损失。对于回归问题，我们使用rmse作为标签丢失。

具有训练后的最优参数的标签分类器适合于目标域。

$$y_{pre} = G_y(GH(f(x; \Theta); W_Q, W_K, W_V), \phi). \quad (14)$$

目标函数时序列域自适应的预测对准模型的总损失表述为：

$$\text{which } \omega \text{ 中的 } L(\Theta, W_Q, W_K, W_V, \phi) = L_y + \omega(L\alpha + L\beta), \quad (15) \text{ 为超参数。}$$

在上述目标函数下，我们的模型使用以下方法对源领域和目标领域进行训练：

$$(\Theta, W_Q, W_K, W_V, \phi) = \underset{\Theta, W_Q, W_K, W_V, \phi}{\arg \min} \kappa(W_V, \phi). \quad (16)$$

## 实验结果

### 设置

#### 锅炉故障检测数据集。bo iler数据标

2014年3月24日期间三个锅炉的传感器数据来源

2016/11/30.这个数据集有3台锅炉

锅炉被认为是一个领域。学习的任务是为了

预测每个锅炉的故障排污阀。自

故障数据非常罕见。很难获得故障样本

在机械系统。因此，利用种子源数据和未标记目标数据来提高模型泛化是很重要的。

空气质量预测数据集。空气质量预测数据集(Zheng et al. 2015)在UrbanAir项目12014/05-04/30中收集，其中包含空气质量数据、气象数据和天气预报数据等。该数据集涵盖了中国的4个主要城市：北京(B)、天津(T)、广州(G)和深圳(S)。我们使用空气质量数据作为天气气象数据来预测PM2.5。我们选择错过价值最小的空气质量站，并将每个城市作为一个域。我们使用这个数据集是因为空气质量数据是常见的，而智能城市系统中的传感器通常包含补偿词汇因果关系。传感器之间的关联通常是稀疏的，这是我们的模型的。

住院期间死亡率预测数据集。MIMIC- III(约翰逊等人，2016年；切等人，2018年)2是另一个已发表的数据集，该数据集与2001年至2012年期间住在贝斯以色列女执事医疗中心重症监护病房的4万多名健康相关患者相关。它是时间序列域自适应的基准

<sup>1</sup><https://www.microsoft.com/en-us/research/project/urban-air/>  
<sup>2</sup><https://mimic.physionet.org/gettingstarted/demo/>



方法	B→T	G→T	S→T	T→B	G→B	S→B	B→G	T→G	S→G	B→S	T→S	G→S	平均
LSTMS2T	40.20	41.67	48.91	52.81	56.44	68.14	19.00	19.76	17.56	13.82	13.82	13.86	33.83
RDC	39.72	40.80	47.75	51.98	55.83	67.67	18.18	19.10	15.43	13.70	13.75	13.76	33.14
罗丹	39.93	40.98	46.16	52.72	55.65	66.47	18.00	18.47	15.18	13.82	13.78	13.79	32.91
维拉达	38.12	38.69	45.29	52.14	54.51	64.41	17.30	17.95	14.63	13.80	13.90	13.80	32.04
SASA- $\alpha$	36.60	34.42	41.31	48.34	54.20	59.09	16.42	16.48	14.30	13.68	13.53	13.47	30.15
SASA- $\beta$	35.54	35.10	42.16	48.40	54.42	60.45	16.66	16.58	14.62	13.62	13.49	13.68	30.39
萨萨	<b>34.26</b>	<b>33.84</b>	<b>40.91</b>	<b>48.15</b>	<b>54.14</b>	<b>56.80</b>	<b>16.40</b>	<b>15.41</b>	<b>14.23</b>	<b>13.49</b>	<b>13.46</b>	<b>13.38</b>	<b>29.54</b>

表1：关于空气质量预测的RMSE。

方法	2→1	3→1	4→1	1→2	3→2	4→2	1→3	2→3	4→3	1→4	2→4	3→4	平均
LSTMS2T	80.52	78.79	76.85	80.24	81.43	77.24	75.77	79.30	75.56	65.79	68.93	69.41	75.82
RDC	81.36	78.94	77.11	80.66	82.40	78.47	75.96	79.39	75.63	66.20	69.59	70.21	76.33
罗丹	81.38	79.30	77.57	80.70	82.71	78.38	76.00	79.18	76.18	66.64	69.83	69.62	76.46
维拉达	82.12	80.68	77.71	82.24	83.09	78.82	76.27	80.00	76.28	68.20	70.01	71.34	77.23
SASA- $\alpha$	84.62	81.02	79.89	83.36	84.12	80.78	76.78	80.72	78.37	68.65	70.62	72.23	78.47
SASA- $\beta$	83.68	81.47	78.36	82.70	84.36	81.20	77.14	80.52	77.86	68.23	70.35	72.57	78.20
萨萨	<b>85.03</b>	<b>82.91</b>	<b>80.32</b>	<b>83.82</b>	<b>85.20</b>	<b>82.03</b>	<b>77.83</b>	<b>81.10</b>	<b>78.93</b>	<b>69.02</b>	<b>70.96</b>	<b>72.76</b>	<b>79.16</b>

表2：对住院死亡率预测的AUC评分（%）。

等人，2017年)。与普兰等人（普山等人2018）类似，我们从35637条记录中选择了12个时间序列（如心率、温度、收缩压等）。为了准备用于时间序列域适应的住院死亡率预测数据集，我们将患者按年龄分为4组（第4组1：20-45，第2组：46-65，第3组：66-85，第4组：>85）。

方法	锅炉	空气	模拟iii
LSTM S2T	82924	46191	72106
RDC	82924	46191	72106
罗丹	82652	46183	71479
维拉达	83532	45898	72784
我们的	82322	45636	71402

表3：所有方法无关数据集的参数总数。

基线

**LSTM S2T。**LSTM S2 T使用源域数据训练一个香草的LSTM模型，并将其应用于目标主，而没有任何适应（S2 T代表源totar-get）。预计它将提供较低值的边界性能。  
**R- DANN.R- DANN**（da Costa等人2020）是一种非监督的域适应架构（Ganin和兰皮茨基2015），在LSTM上带有GRL（梯度反转层），这是时间序列域适应的直接解决方案。  
**RDC。**深度域混淆是一种无监督的主自适应方法（Tzeng et al. 2014），该方法通过使用极大的意义分布（MMD）使源和获取分布之间的距离最小化。与前面的R-DANN类似，我们使用LSTM作为时间序列数据的特征提取器。  
**弗拉达语。**VRADA（普罗索瑟姆等2017）是一种时间研究的无监督域自适应方法，结合GRL和VRNN（Chung等2015）。

为了进行公平的比较，所有基线的参数总数和我们的方法都是相同的，如表3所示。我们在每个数据集上使用相同的参数组合，并在每个实验中应用三种不同的随机种子。

模型变体

为了验证我们模型的每个组件的有效性，我们进一步设计了以下模型变量。

**SASA- $\alpha$ ：**我们删除 $L\alpha$ 来验证片段长度限制损失的有效性。

**SASA- $\beta$ ：**我们删除 $L\beta$ 来验证解析关联结构对齐丢失的有效性。

结果

锅炉故障检测的结果。锅炉故障检测数据集的AUC结果如表4所示。我们的SASA模型在所有任务上都显著优于其他基线。值得一提的是，我们的稀疏关联结构对齐模型在更难的转移任务上显著提高了AUC得分，例如1→2和3→2，与VRADA相比，它们分别提高了3.95和2.56分。在一些简单的任务上，如1→3、2→3和3→1，尽管其他基线表现得很好，但我们的方法仍然取得了一个可比较的结果。我们还对报告的分数进行了Wilcoxon符号秩检验（Wilcoxon1945），p值为0.027，这意味着我们的方法在p值阈值下显著优于基线。

方法	1→2	1→3	3→1	3→2	2→1	2→3	平均
LSTM S2T	67.09	94.54	93.14	56.09	84.99	91.31	81.19
RDC	68.29	94.65	93.38	57.32	85.31	92.57	81.92
罗丹	67.71	94.69	93.92	58.53	85.67	91.66	82.03
维拉达	67.59	94.88	93.65	60.59	85.96	92.62	82.55
SASA- $\alpha$	70.83	95.86	94.63	60.76	87.27	93.28	83.77
SASA- $\beta$	69.76	95.01	94.56	61.31	86.78	92.84	83.38
萨萨	<b>71.54</b>	<b>96.39</b>	<b>94.77</b>	<b>63.15</b>	<b>87.76</b>	<b>93.59</b>	<b>84.53</b>

表4：锅炉故障检测的AUC评分（%）。


产生空气质量预测。与锅炉故障检测数据集的结果相似，我们的模型在所有任务上也取得了很好的结果，优于所有其他基线，这在t表1中报道。根据结果，我们可以观察到：1)拥挤城市之间的表现优于其他城市。例如，由于北京和天津之间的距离小于北京和广州和北京到深圳之间的距离， $B \rightarrow T$ 的推广优于 $B \rightarrow G$ 和 $B \rightarrow S$ 。这是因为距离较近的城市对具有更多的联系。2)即使在远离目标城市，如北京和深圳，我们的方法仍然取得了最好的效果，这一现象表明，我们的稀疏关联结构对齐模型很好地提取了不同变量之间的关联结构。3)当以深圳作为目标域时，与其他任务相比，性能并不那么显著。这是因为这个域的标签值比其他域要低得多。我们还对报告的分数进行了Wilcoxon符号秩检验（Wilcoxon1945）值为0.002，这意味着我们的方法在p值阈值为0.0时显著优于基线

住院死亡率预测的结果。我们还在MIMIC-III dataset上证明了我们的模型，该模型被选择为（Pu- rushotham et al. 2017）中时间序列域自适应的基准模型。在（普鲁索坦等人，2018年）中描述了12个变异，并重现了VRADA的类似结果。如表2所示，我们的模型在所有转移任务上都超过了其他比较方法。一些领域的适应任务，如 $2 \rightarrow 1$ 和 $3 \rightarrow 2$ ，甚至分别提高了2.91分和2.11分。此外，我们还发现1和2、2、3以及3和4之间的性能优于其他的。我们还进行了威尔科森符号跑k检验

在报告的得分上，p值为0.0022，p值阈值为0.05。

### 消融研究和可视化

对片段长度限制的有效性的研究。为了验证透明结构重新排列的有效性，我们去掉了 $L\alpha$ ，该模型命名为SASA- $\alpha$ 。比较SASA和SASA- $\alpha$ 的结果，我们可以发现SASA- $\alpha$ 的性能下降。这是因为 $\alpha$ 代表了节段长度的概率。节段的持续时间随域而变化。



(a) 北京 (b) 深圳

图4：北京→深圳相邻矩阵相关结构可视化示意图。颜色越深，关系就越强。我们可以确定这个结构是稀疏的。

通过限制 $\alpha$ ，我们可以排除域特定片段持续时间的干扰。

稀疏结合结构对齐的有效性研究。为了验证片段长度限制的有效性，我们消除了稀疏关联脉叶结构对齐损失。根据SASA- $\beta$ 的实验结果，我们可以发现SASA- $\beta$ 的性能比标准的SASA要差。这是因为提取了稀疏社会结构，也比正常特征提取器更鲁棒。但保留域的特异性关联关系导致了这些时间结果。请注意，SASA- $\beta$ 仍然优于其他基线。这是因为 $L\alpha$ aligns是不同域之间的偏移，有利于提取透明结构进行适应。

对准结构的可视化。为了进一步研究我们的方法，我们在空气质量数据集上对对齐的稀疏关联结构进行可视化，并尝试提取常见的稀疏关联结构，如图4所示。可视化结果直观地显示了北京和深圳的稀疏关联结构。颜色越深，两个变量之间的关联性就越强。我们可以发现(1)来自不同领域的联想结构是非常稀疏的。(2)来自源域和目标域的稀疏关联结构具有许多共享的关联关系，即相似的稀疏关联结构是共享的无关域。

### 结论

本文提出了一种时间序列无监督域适应的稀疏关联结构实际组合模型。在我们的建议中，采用稀疏的社会结构发现方法，结合自适应的序列段总结，提取时间序列的结构，并采用基于MMD的结构对齐方法将知识从源域转移到目标域。该方法的成功不仅为时间序列-主自适应任务提供了一个有效的解决方案，而且对时间序列数据的可转移性提供了一些深刻的见解。

## 确认信息

本研究部分由中国国家自然科学基金(61876043,61976052)、广州科技规划项目资助(201902010058)。

## 关于潜在的伦理影响的声明

基于相关关系的时间序列域自适应模型比现有方法更稳健,在非标签测试数据中具有显著的性能,可以应用于机械系统、智能城市和医疗保健。应用我们的方法的积极影响包括:

(1)对时间序列数据的无监督域映射的显著改进,减少了人工获取标记数据的要求,并使机器学习模型可用于使用低资源集。

(2)对时间序列数据的无监督域自适应有利于缓解网络过拟合。

然而,使用智能植入式人工智能技术所产生的负面影响也不应被忽视。这些技术缺乏可解释性,因此有时难以被信任。我们的方法在某种程度上可以解决这个问题,但如果我们考虑到因果关系,它会更好。

## 参考文献

巴赫达瑙, D.; 赵, K.; 和Bengio, Y. 2015.联合学习和翻译的神经马下巴翻译。在Y.; , eds. 国际会议, IC LR2015, 美国圣地亚哥, 美国, 2015年5月7-9日, 会议跟踪进展。紫外线<http://arxiv.org/abs/1409.0473>。

蔡先生; 李, Z.; 魏, P.; 乔的某人, J.; 张勇, K.; 和郝, Z。

2019.学习主适应的语义表征。在IJCAI: 会议论文集, 2019卷, 2060卷。NIH公共访问系统。

切, z; Purushotham, S.; 赵; K.; Sontag, D.; 和刘, Y. 2018.具有缺失值的多元时间序列的循环神经网络。科学报告8(1): 1—12。

钟, J.; 卡斯特纳, K.; 丁L.; 目标K.; 库维尔。C.; 和本, Y. 2015.序列数据的递归潜在变量模型。在神经信息处理系统的研究进展中, 2980—2988。

daCosta, P.R.d.O.; 阿, ; 张, Y.; 一个dKaymak, U. 2020.通过深度域自适应进行剩余有用的寿命预测。可靠性工程和系统安全195: 106682。

Ganin, Y.; 和兰皮茨基, 2015年版。反向传播后的无监督域自适应。在国际会议上的机器学习会议上, 1180—1189。PMLR。

日尔曼, p; 一个; 拉维莱特, F.; andMorvant,E. 2016.一种新的pac-贝叶斯视角。关于机器学习国际会议, 859—868。

古德费罗, 我; 小Abadie, J.; Mirza, M.; 徐, b. 沃德法利, D.; Ozair, 美国; 库尔维尔, A.; andBengio,Y. 2014.生成的对抗性网络。在新的II信息处理系统的进展, 2672—2680。

戈亚尔、A.、羔羊, A.; 霍夫曼J.; SodhaniS; 莱文美国; 本, Y.; 和Schlkopf, B.2019.循环独立机制。arXiv预印本arXiv: 1909.10893。

詹森, A.E.; 波拉德, t.J.; 沈, L.; 李伟, H.L.; 冯, M.; 加阿西米先生; 穆迪, B.; , p; Celi, L. A.;和Mark, R. G. 2016. MIMIC- III, 一个免费访问的护理数据库。科学数据3: 160035。

林, B. Y.; 和陆, W. 2018.跨域命名实体识别的神经自适应层。在2018年自然语言处理经验方法会议的论文, 2012—2022。

长, M.; 曹, Y.; 王, J.; 和乔丹, M. 2015.通过深度自适应网络来学习可转移的特性。在机器学习国际会议上, 97—105。PMLR。

马丁斯也来了。; andAstudillo,R.2016.一种注意力的稀疏模型和多标签分类的稀疏模型。在国际会议上, 机器学习, 1614—1623。

米科洛夫, T.; 卡拉菲特, M.; Burget, L.; y, J.; 和胡-丹普尔, S. 2010年。基于循环神经网络的语言模型。国际言论传播协会年会。Černock

潘, S. J.; 曾荫权, i.W.; 郭, J.T.; 以及通过转移组件分析进行的Yang, Q.2010.Domain自适应。神经网络上的电子交易系统22(2): 199—210。

潘, S. J.; 和杨, Q. 2009.一个关于迁移学习的调查。IEEE知识和数据工程交易环22(10): 1345—1359。

Purushotham,S.; 卡瓦略, W.; 尼兰农, T.; andLiu,Y. 2017.变分循环的深度域适应。在第五届国际学习代表会议上, ICLR2017, 法国土伦, 2017年4月24-26日, 会议跟踪记录。开放审查。网紫外线<https://openreview.net/forum?id=rk9eA Fcxg>。

Purushotham, 美国; 孟, C.; 切, Z.; andLiu,Y.2018.在大型健康护理人员数据集上进行基准测试的深度学习模型。生物医学信息学杂志83: 112—134。

孙, B.; 冯, J.; 和Saenko, K. 2016.回归是非常容易的领域适应。在第三十届AAAI举办的人工智能会议上。

曾, E.; 霍夫曼, J.; Saenko, K.; 和Darrell, T.2017.Adversarial鉴别域自适应。在IEEE计算机视觉和模式识别会议的进展中, 7167—7176。

曾, E.; 霍夫曼, J.; 张, N.; Saenko, K.; 和达雷尔, T. 2014.深度域混淆: 域不变性的最大化。arXiv预印本arXiv: 1412.3474。



Vaswani, A.; Shazeer, N. ; Parmar, N. ; Uszkoreit, J. ; 琼斯, L. ; 戈麦斯, A.N. ; 凯泽, k ; 波洛苏欣, I.2017.At-紧张是你所需要的。在神经元信息处理系统的研究进展中, 5998—6008。

王, X. ; 李, L. ; 你的, W. ; 长, M. ; 以及Wang, J.2019.Transferable对完全适应的关注。InAAAI会议关于人工智能 ( AAAI ) 。

魏, p. ; 柯, Y. ; andGoh,C.K.2016.无监督域自适应的深度非线性特征编码。在IJCAI, 2189—2195。

魏, P. ; 柯, Y. ; 和Goh, C.K.2018。边缘堆叠表示非监督域自适应的自编码器的特性分析。IEEE交易在神经网络-工作和学习系统30(5) : 1321—1334。

温J. ; 刘R. ; 郑, n. ; 郑, 问. ; 龚, Z. ; andYuan, J.2019.利用局部特征模式进行非监督域自适应。AAAI人工智能会议论文集, 第33卷, 5401—5408。

Wilcoxon,F.1945.通过排名的方法进行个人比较。Biometrics1(6): 80—83。

谢S. ; 郑Z. ; 陈, L. ; 和Chen, C.2018。学习无监督域映射的语义表示。在机器学习国际会议上, 5419—5428。

张, K. ; 龚, M. ; 和Schlkopf, B.2015。多资源域的适应：一个因果关系的视图。第二十九届人工智能会议。ö

张, K. ; Schlkopf,B.;Muandet, K.; andWang,Z.2013.在tar获取和条件转移下的领域适应。在机器学习国际会议上, 819—827。ö

张Y. ; 刘, T. ; 长, M. ; andJordan,M.2019.域自适应的桥梁理论和算法。在关于机器学习的国际会议上, 7404—7413。

郑Y. ; 易X. ; 李m. ; 李R. ; 山Z. ; 张E. ; 和李, T. 2015。基于大数据预测细粒度空气质量。在第21届thACM SIGKDD国际会议与知识发现和数据评估的论文集中, 2267—2276。ACM。